

Aprendizado de Máquina

Trabalho Prático 2

Luís Felipe Ramos Ferreira
2019022553
lframes_ferreira@outlook.com

June 20, 2023

1 Introdução

O Trabalho Prático 2 da disciplina de Aprendizado de Máquina teve como objetivo o desenvolvimento de um algoritmo de *boosting* para classificação binária. Em particular, o algoritmo a ser desenvolvido é o *Adaboost* e a base de dados a ser utilizada nos testes é o conjunto *Tic-Tac-Toe*. Além disso, os modelos criados deveriam ser analisados por meio da metodologia de validação cruzada com 5 partições para avaliação do modelo.

2 Implementação

A linguagem escolhida para o desenvolvimento do trabalho foi *Python* (versão 3.10), devida a sua grande variedade de bibliotecas úteis para ciência de dados e aprendizado de máquina. A modelagem do algoritmo *AdaBoost* foi feita com o uso de bibliotecas de análise numérica como *NumPy* e *Pandas*, uma vez que se tratam de ferramentas extremamente completas que facilitaram o desenvolvimento do algoritmo.

Para organizar o ambiente de desenvolvimento, que englobava vários pacotes diferentes, foi utilizado o gerenciador de pacotes *Anaconda*, o que facilitou o trabalho com os pacotes de ciência de dados citados. O projeto final foi salvo em um [repositório](#) no GitHub para fácil versionamento e organização de código.

2.1 Classificador

A implementação do classificador *AdaBoost* seguiu o padrão utilizado pela biblioteca *NumPy*, de modo que armazenar o classificador e todas as suas funcionalidades em um objeto permitia uma maior abstração do código e facilitou seu uso. A classe em questão possui um construtor e os métodos de treinamento e predição.

A implementação foi pensada especificamente para a classificação binária, de modo que bases de dados com mais de duas classes não irão funcionar. Como já citado, as funcionalidades das bibliotecas *NumPy* e *Pandas* foram extensamente utilizadas durante o desenvolvimento.

2.2 Validação cruzada

A implementação da validação cruzada foi feita conforme o conteúdo teórico ensinado nas aulas. De maneira geral, também foi utilizada a documentação da biblioteca *Scikit-Learn* para consolidar a implementação e corroborar com o conhecimento sobre o método.

3 Análise dos resultados de teste

Conforme especificado no enunciado, foi realizada a análise do modelo de *AdaBoost* criado com o uso de uma validação cruzada de 5 partições. Dessa maneira, a base inteira de dados *Tic-Tac-Toe* foi

dividida em 5 partes, as quais foram utilizadas para treino e validação iterativamente. Os resultados de métricas de análise para cada uma das partições foi armazenado e, ao fim dos cálculos, as médias foram retiradas para que um valor geral representativo do modelo pudesse ser gerado.

De modo a compreender como a variação do número de estimadores impacta em um algoritmo de *boosting*, o *pipeline* descrito acima foi feito para números de estimadores variando de 1 a 400, e um gráfico que representa como as métricas variam conforme o número de estimadores aumenta pode ser gerado.

Os gráficos em questão podem ser vistos abaixo:




Figure 1: Evolução do erro em função do número de estimadores




Figure 2: Evolução da acurácia em função do número de estimadores




Figure 3: Evolução do F1-Score em função do número de estimadores

4 Conclusão

Em suma, após as análises e discussões apresentadas neste relatório, fica claro que os parâmetros da rede neuronal, como o número de neurônios na camada oculta,